

Лабораторная работа №2

Однослойный перцептрон: реализация, обучение и анализ

Работа выполнена автономно на Python. Модель перцептрона реализована с нуля: готовые ML-модели не использовались. sklearn применён только для генерации рекомендованного набора данных и стратифицированного разбиения.

Базовые параметры: $\eta = 0.1$, $\text{epochs} = 100$, $\text{batch_size} = 32$, $\text{random_state} = 42$. Тестовая выборка одновременно использована как validation-набор для построения кривых loss, потому что отдельная validation-выборка в задании не задана.


1. Теоретическая часть и реализация

Перцептрон вычисляет $z = \mathbf{w}^T \mathbf{x} + b$ и для BCE использует $\text{sigmoid}(z) = 1 / (1 + \exp(-z))$. Оптимизация выполняется mini-batch gradient descent. Для BCE градиент по весам имеет вид $\mathbf{X}^T(\mathbf{y}_{\text{hat}} - \mathbf{y}) / m$; для hinge loss обновляются только объекты с margin меньше 1.


В реализации есть варианты инициализации весов: нулевая, малая случайная $N(0, 0.01)$ и большая случайная $N(0, 10)$. Также поддержаны L2-регуляризация и momentum с β из набора 0.5, 0.9, 0.99.

2. Базовое обучение


split	accuracy	precision	recall	f1	roc_auc
train	0.8657	0.8486	0.8920	0.8698	0.9311
test	0.8867	0.8537	0.9333	0.8917	0.9413




Разделяющая граница базовой модели



ROC-кривая базовой модели






Итоговая test accuracy базовой модели: 0.8867; ROC-AUC: 0.9413; F1-score: 0.8917.

3. Обязательные эксперименты

Влияние скорости обучения


lr	train_accuracy	test_accuracy	final_val_loss	weight_norm
0.0010	0.8571	0.8800	0.5930	0.3338
0.0100	0.8600	0.8867	0.3741	1.6793
0.5000	0.8657	0.8867	0.3009	3.2536
1.0000	0.8686	0.8867	0.3006	3.2555



Лучший результат среди проверенных eta по test accuracy: eta = 0.01 с accuracy = 0.8867. Малые eta дают медленную сходимость, слишком крупные могут увеличивать колебания loss.

Влияние размера batch


batch_size	train_accuracy	test_accuracy	final_val_loss	weight_norm
1.0000	0.8657	0.8867	0.3002	3.2763
16.0000	0.8657	0.8867	0.3011	3.2440
64.0000	0.8629	0.8867	0.3089	2.9149
256.0000	0.8600	0.8867	0.3393	2.1737



Лучший batch по test accuracy: 1. Batch = 1 даёт более шумную траекторию, крупные batch делают обновления стабильнее, но иногда медленнее реагируют на структуру данных.

Влияние инициализации весов

init	train_accuracy	test_accuracy	final_val_loss	weight_norm
zero	0.8657	0.8867	0.3029	3.1512
small_random	0.8657	0.8867	0.3029	3.1511
large_random	0.8657	0.8867	0.3039	3.1069




Большая случайная инициализация может насыщать sigmoid и ухудшать начальные градиенты. Малая случайная и нулевая инициализации для однослойной модели работают приемлемо, потому что проблемы симметрии скрытых нейронов здесь нет.

4. Дополнительные задания


Собственный генератор данных

dataset	train_accuracy	test_accuracy	test_f1	final_val_loss
linear	0.9686	0.9800	0.9801	0.0956
xor	0.6400	0.6133	0.5538	0.6953
circle	0.8057	0.8067	0.0000	0.4918


Собственный генератор: linear



Собственный генератор: xог




Собственный генератор: circle





На линейно разделимых данных перцептрон строит корректную прямую границу. На XOR и окружности одна прямая не может описать истинное правило, поэтому качество ограничено геометрией модели.

Hinge loss и L2-регуляризация

loss	train_accuracy	test_accuracy	test_f1	final_val_loss
bce	0.8657	0.8867	0.8917	0.3029
hinge	0.9000	0.9200	0.9259	0.3007



l2	test_accuracy	final_val_loss	weight_norm
0.0000	0.8867	0.3029	3.1511
0.0010	0.8867	0.3097	3.0576
0.0100	0.8867	0.3546	2.4841
0.1000	0.8867	0.4978	1.2123
1.0000	0.8800	0.6469	0.2891



L2-регуляризация уменьшает норму весов и может улучшать обобщение, если коэффициент умеренный. Слишком большой lambda переусиливает штраф и ухудшает fit.


Метрики качества и анализ ошибок

Для тестовой выборки рассчитаны accuracy, precision, recall, F1-score и ROC-AUC. Ошибки визуализированы поверх разделяющей границы; они концентрируются около переходной области между классами.

Momentum

momentum	test_accuracy	final_val_loss	weight_norm
0.0000	0.8867	0.3029	3.1511


momentum	test_accuracy	final_val_loss	weight_norm
0.5000	0.8867	0.3012	3.2415
0.9000	0.8867	0.3013	3.2463
0.9900	0.8867	0.3012	3.2593




Наименьший validation loss среди momentum-настроек получен при $\beta = 0.99$. Слишком высокий β может вызывать инерционные колебания около минимума.

5-fold cross-validation

lr	batch_size	mean_accuracy	std_accuracy
0.0100	16.0000	0.8629	0.0278
0.0100	32.0000	0.8572	0.0335
0.0100	64.0000	0.8515	0.0376
0.1000	16.0000	0.8658	0.0209
0.1000	32.0000	0.8629	0.0191
0.1000	64.0000	0.8629	0.0191
0.5000	16.0000	0.8629	0.0191
0.5000	32.0000	0.8629	0.0191
0.5000	64.0000	0.8657	0.0212



Лучшие параметры по 5-fold CV: $\eta = 0.1$, $\text{batch_size} = 16$, mean accuracy = 0.8658 ± 0.0209 . Финальная модель с этими параметрами дала test accuracy = 0.8867.



Выводы

Однослойный перцептрон с sigmoid и BCE успешно решает двумерную бинарную классификацию, когда классы близки к линейно разделимым. Скорость обучения, размер batch и масштаб начальных весов заметно влияют на сходимость. Ограничение модели принципиально: для XOR и круговой структуры требуется нелинейная модель или расширение признакового пространства.