

Теоретическое дополнение к лабораторной работе

Однослойный перцептрон

Данный документ содержит краткое изложение теоретических понятий, необходимых для выполнения лабораторной работы. Предполагается, что основные формулы и определения уже известны из лекций; здесь они приведены в свернутом виде для удобства.

1 Модель перцептрона

Перцептрон — простейший вид нейронной сети, предназначенный для бинарной классификации. Он вычисляет взвешенную сумму входов, добавляет смещение и пропускает результат через нелинейную функцию активации:

$$z = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^d w_i x_i + b, \quad \hat{y} = \sigma(z).$$

Здесь $\mathbf{x} \in \mathbb{R}^d$ — вектор признаков, $\mathbf{w} \in \mathbb{R}^d$ — веса, b — смещение, $\sigma(\cdot)$ — сигмоидная функция.

1.1 Сигмоидная функция активации

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Её свойства:

- Область значений: $(0, 1)$ — выход интерпретируется как вероятность.
- Монотонно возрастает.
- Производная выражается через саму функцию: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

Благодаря гладкости и простоте производной сигмоида удобна для градиентного обучения.

2 Функция потерь

Для бинарной классификации используется **бинарная кросс-энтропия** (log-loss). Для одного примера:

$$L = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})].$$

Для батча из m примеров:

$$L = -\frac{1}{m} \sum_{i=1}^m [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)].$$

Смысл: чем ближе предсказание $\hat{y}$ к истинной метке y , тем меньше значение L . Если предсказание уверенно и правильно, L близка к 0; если уверенно и неправильно — L стремится к $+\infty$.

3 Градиентный спуск

Обучение модели заключается в минимизации функции потерь $L(\mathbf{w}, b)$. Для этого используется итерационный метод градиентного спуска. На каждом шаге параметры обновляются в направлении, противоположном градиенту:

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{\partial L}{\partial \mathbf{w}}, \quad b \leftarrow b - \eta \frac{\partial L}{\partial b}.$$

Здесь $\eta > 0$ — **скорость обучения** (learning rate) — гиперпараметр, определяющий размер шага.

3.1 Градиенты для кросс-энтропии с сигмойдой

Удивительным образом, несмотря на нелинейность, градиенты принимают простой вид:

$$\frac{\partial L}{\partial \mathbf{w}} = \frac{1}{m} \mathbf{X}^T (\hat{\mathbf{y}} - \mathbf{y}), \quad \frac{\partial L}{\partial b} = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i),$$

где $\mathbf{X}$ — матрица входов размера $m \times d$, $\hat{\mathbf{y}}$ — вектор предсказаний, $\mathbf{y}$ — вектор истинных меток.

Этот результат получается при помощи цепного правила, и его вывод — важное упражнение, но здесь он опущен. Важно запомнить: ошибка $\hat{y}_i - y_i$, умноженная на вход, даёт градиент по весам.

4 Мини-батчи и эпохи

Обрабатывать все обучающие примеры одновременно может быть накладно по памяти, а по одному — слишком шумно. Компромисс — **мини-батчи**. Выборка разбивается на небольшие группы (например, по 32 или 64 примера), и градиент вычисляется по каждой группе отдельно.

Эпоха — один полный проход всех примеров через алгоритм (т.е. количество обновлений = число примеров / размер батча).

Перед каждой эпохой данные рекомендуется **перемешивать**, чтобы сеть не запоминала порядок.

5 Предобработка данных

5.1 Стандартизация признаков

Признаки могут иметь разный масштаб (например, возраст от 0 до 100 и доход от 1000 до 1 000 000). Это приводит к несбалансированным градиентам и плохой сходимости. Поэтому перед обучением применяют **Z-нормализацию**:

$$x' = \frac{x - \mu}{\sigma},$$

где μ и σ — среднее и стандартное отклонение, вычисленные по **обучающей выборке**. Эти же параметры затем используются для тестовой выборки.

5.2 Стратификация

При разделении данных на обучающую и тестовую части важно сохранить пропорцию классов. Иначе, например, в тесте может оказаться только один класс, и метрики станут бессмысленными. Стратифицированное разбиение решает эту проблему.

6 Метрики качества

Для оценки модели после обучения вычисляют:

- **Accuracy** (доля правильных ответов): $\frac{TP+TN}{TP+TN+FP+FN}$.
- **Precision** (точность): $\frac{TP}{TP+FP}$.
- **Recall** (полнота): $\frac{TP}{TP+FN}$.
- **F1-score**: $2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$.

Эти метрики особенно важны при дисбалансе классов.